

Per-Layer Learnable Hyperbolic Curvature for Three-Layer RQ-VAE in Generative Recommendation

Anonymous

1 引言

1.1 分层码本的几何异质性与共享曲率的局限

RQ-VAE [4] 通过逐层量化残差，将连续 item representation 转换为 coarse-to-fine 的离散 semantic identifiers [6, 7]。给定编码表示 z ，第 ℓ 层从码本

$$\mathcal{E}_\ell = \{e_{\ell k}\}_{k=1}^{K_\ell} \quad (1)$$

中选择与当前残差最接近的码字，并将尚未被解释的信息传递至下一层：

$$r_0 = z, \quad k_\ell^* = \arg \min_k d(r_\ell, e_{\ell k}), \quad r_{\ell+1} = r_\ell - e_{\ell k_\ell^*}. \quad (2)$$

因此，不同 RQ stage 实际处理的是逐层变化的 residual representation。本文关注的问题是：当不同量化层形成不同的表示结构时，是否仍应要求它们共享完全相同的几何度量与曲率？semantic tokenization 不仅需要压缩 item embeddings，还需要保留对推荐有用的 item relationships——仅依赖 reconstruction 的 RQ-VAE 可能破坏 item neighborhood，而显式保留 topology 可得到更有效的 semantic tokens (CoST [9]、TopoTok [8])。据此，我们依次验证两个问题：(1) 不同 RQ stage 是否形成了相同的 codebook geometry？

(2) 若不同，各层是否具有不同的 curvature preference？

问题 1: codebook geometry 是否层间一致？

观察 1 (residual 异质性)。在 Vanilla-RQ 中：

- 三层 residual norm 均值随量化深度稳定下降，Kolmogorov-Smirnov 检验表明各 stage 分布显著不同。
- 在统一码本规模

$$K \in \{64, 128, 256\}, \quad (3)$$

下，layer-dependent pattern 保持稳定，说明该异质性是 residual quantization 深化本身的结构性结果。

观察 2 (codebook 几何异质性)。三个层面的指标 (表 1、图 1) 呈现逐层一致的模式：

- 全局： $\tilde{d}_{\text{pair}}^{(0)} > \tilde{d}_{\text{pair}}^{(1)} > \tilde{d}_{\text{pair}}^{(2)}$ ，L0/L2 码字间距比 2.25×–2.49×；
- 局部：NN distance 逐层递减 (L0/L2 比 1.60×–1.78×)，local density 递增；
- 谱：effective rank 递增而第一主方向方差递减——排除“同一结构的均匀缩放”这一替代解释。

因此，随 RQ depth 增加，codebook geometry 由

$$\text{broad / sparse / anisotropic} \rightarrow \text{compact / dense / more isotropic}, \quad (4)$$

过渡，可概括为

$$G(\mathcal{E}_0) \neq G(\mathcal{E}_1) \neq G(\mathcal{E}_2), \quad (5)$$

其中 $G(\mathcal{E}_\ell)$ 表示由全局距离、局部邻域与谱结构共同描述的第 ℓ 层 codebook geometry。

从几何异质到曲率异质。codebook geometry 不同本身不足以推出 curvature 不同：(i) 距离尺度的差异可由全局缩放解释；(ii)

表 1: 三层 codebook 几何异质性汇总 (三种统一码本规模 $K = 64/128/256$)。KS/ W_1 为 $K = 128$ 下 L0 与 L2 完整 pairwise-distance distributions 的差异；NN ratio 为 L0/L2 平均 nearest-neighbor distance 之比。

Metric	L0	L1	L2
<i>Mean pairwise distance</i>			
$K = 64$	0.1922	0.1059	0.0856
$K = 128$	0.1946	0.1060	0.0839
$K = 256$	0.1993	0.1035	0.0799
<i>NN distance</i>			
$K = 64$	0.1095	0.0809	0.0686
$K = 128$	0.1044	0.0767	0.0641
$K = 256$	0.1015	0.0703	0.0570
<i>Local density ($k = 5$)</i>			
$K = 64$	8.08	11.78	13.97
$K = 128$	8.47	12.46	14.96
$K = 256$	8.89	13.52	16.74
<i>Effective rank</i>			
$K = 64$	12.80	18.54	20.05
$K = 128$	15.65	22.17	23.64
$K = 256$	17.61	24.31	25.77
<i>PC1 variance</i>			
$K = 64$	21.89%	8.92%	7.76%
$K = 128$	20.54%	8.36%	6.33%
$K = 256$	17.52%	7.20%	5.58%
<i>NN ratio (L0/L2)</i>			
KS / W_1 (L0 vs. L2, $K = 128$)	$1.60\times / 1.63\times / 1.78\times$ ($K = 64/128/256$) $D_{\text{KS}} = 0.9824, W_1 = 0.1107$		

RQ-VAE 的输入是连续 item embeddings 而非 graph，不能依预设 tree/graph 假设推断双曲。

问题 2: 各层是否具有不同的 curvature preference？

诊断方法 (图 2)。构造 curvature-independent relational reference: 对每个 codeword，由其量化 items 与其他 codeword 对应 items 的关系构造 item-induced affinity，保留 top-10 邻接形成 relational graph，以图上 shortest-path distance 定义参考距离

$$D_\ell^{\text{ref}}. \quad (6)$$

D_ℓ^{ref} 并非 ground-truth geometry，仅回答：哪一种曲率能以更低失真表达已学习到的 item 关系？(与 topology-preserving tokenization 动机一致 [8, 9])

随后在曲率集合

$$c \in \{0, 0.01, 0.05, 0.1, 0.5, 1, 2, 5, 10\} \quad (7)$$

上 sweep ($c = 0$ 即 Euclidean geometry)，对每个 layer-curvature pair 求解最优全局尺度

$$a_{\ell,c}^* = \arg \min_a \sum_{i,j} \left(a D_\ell^{(c)}(i,j) - D_\ell^{\text{ref}}(i,j) \right)^2. \quad (8)$$





图 1: 三层 codebook 几何异质性。a, 不同统一码本规模下平均 pairwise distance (对应表 1); b, $K = 128$ 时平均 nearest-neighbor distance 与 local density; c, $K = 128$ 时 effective rank 与第一主方向方差占比。随着 RQ depth 增加, 码本几何由 broad/sparse/anisotropic 向 compact/dense/more isotropic 过渡。



Post-hoc diagnostic only; relational graph is not an RQ-VAE input.

图 2: Post-hoc curvature preference diagnostic. 训练结束后, 从 codewords 与 assignments 出发: 由 assigned-item relationships 构造 relational reference D_{ℓ}^{ref} , 对同一 codewords 在 $c \in \{0, 0.01, \dots, 10\}$ 上计算 $D_{\ell}^{(c)}$, 经全局尺度对齐后比较 distortion. relational graph 仅用于训练后诊断, 不是 RQ-VAE 的输入。

并计算归一化 distortion

$$\text{Distortion}_{\ell}(c) = \frac{\sum_{i,j} \left(a_{\ell,c}^* D_{\ell}^{(c)}(i,j) - D_{\ell}^{\text{ref}}(i,j) \right)^2}{\sum_{i,j} \left(D_{\ell}^{\text{ref}}(i,j) \right)^2}. \quad (9)$$

结果 (图 3、表 2、表 3)。• L0 的最低 distortion 出现在 $c^* = 0$ (Euclidean preference);

• L1/L2 的最低点位于 $c^* \geq 1$ (hyperbolic preference), 相比 Euclidean 改善 1.4%/1.3%;

• 该 ordering 在 $K = 64/128/256$ 下完全稳定, 且不因全局尺度 $a_{\ell,c}^*$ 的优化而消失; Spearman correlation、kNN overlap 与 Gromov δ -hyperbolicity [2] 辅助分析一致。

表 2: $K = 128$ 下各层 curvature preference 汇总。Gromov δ/diam 为归一化 hyperbolicity 度量。

Metric	L0	L1	L2
Best c^*	0	≥ 1	≥ 1
Min distortion	0.0352	0.0280	0.0297
Euclidean distortion	0.0352	0.0284	0.0301
Hyp. improvement	0%	1.4%	1.3%
Gromov δ/diam	0.318	0.303	0.425

表 3: 三种统一码本规模下的 best curvature ordering (robustness)。

K	L0 best c^*	L1 best c^*	L2 best c^*
$K = 64$	0	≥ 1	≥ 1
$K = 128$	0	≥ 1	≥ 1
$K = 256$	0	≥ 1	≥ 1

由此得到从结构异质到曲率异质的直接证据链:

$$G(\mathcal{E}_0) \neq G(\mathcal{E}_1) \neq G(\mathcal{E}_2)$$

$\Downarrow$

$$\text{Distortion}_0(c) \neq \text{Distortion}_1(c) \neq \text{Distortion}_2(c) \quad (10)$$

$\Downarrow$

$$c_0^* = 0, \quad c_1^*, c_2^* \geq 1.$$

为什么深层偏好 hyperbolic? 负曲率提供不同的距离扩张规律: d 维双曲空间体积按

$$V_c(\rho) \propto \exp((d-1)\sqrt{c}\rho) \quad (11)$$




图 3: Layer-wise curvature-distortion curves ($K = 128$)。横轴为曲率 c (对数刻度, 最左为 Euclidean 几何 $c = 0$), 纵轴为归一化 distortion。L0 的最低 distortion 出现在 $c = 0$, 而 L1/L2 的最低点位于 hyperbolic regime ($c \geq 1$), 三层的 curvature preference 清晰分离。

近似指数增长 (欧氏仅为多项式) [2, 3]; 在 Poincaré ball 中, 越接近边界双曲测地距离对位置变化越敏感 (边界在双曲距离意义下位于无限远处) [1, 5]。因此, 当某层关系需要同时保持局部接近与远距离区分时, 负曲率更合适——L1/L2 恰好表现出这种需求, 而 L0 不需要。

结论。 强制所有量化层共享曲率

$$c_0 = c_1 = c_2 = c, \quad (12)$$

意味着三个几何与偏好各异的 codebook 必须使用完全相同的距离扩张规律, 任何单一 c 都只能在两类需求间折衷——较大的 c 使 L0 偏离其最优几何, 较小的 c 无法匹配深层 codebook 的 relational structure。允许曲率随量化层变化

$$c_0, \quad c_1, \quad c_2 \quad (13)$$

是更自然的建模方式。

核心结论: 不同 RQ stage 的 codebook geometry 与 curvature preference 均逐层异质 ($G(\mathcal{E}_0) \neq G(\mathcal{E}_1) \neq G(\mathcal{E}_2)$, $c_0^* = 0$ 而 $c_1^*, c_2^* \geq 1$), 共享单一曲率迫使这些异质几何使用同一距离扩张规律, 构成不必要的几何约束; layer-varying curvature 是更自然的建模方式。

最后, 几何对齐不等于推荐性能: 较低的 relational distortion 不能被直接解释为更高的 Recall/NDCG, 其能否转化为 codeword assignment 与推荐效果的改善, 需由后续 downstream experiments 独立验证 [8, 9]。

2 实验

2.1 复现情况: Amazon Musical_Instruments 基线对比

为验证生成式推荐与序列模型在目标数据集上的可比基线, 我们对 Amazon 2018 Musical_Instruments 5-core (HG-Rec 处理版, 与 DIGER 同源) 进行了系统复现。数据集规模为 24,772 用户 / 9,922 商品 / 206,153 交互 (训练 131,837 样本, 留一法 valid+test)。全部 8 组模型 (BERT4Rec、GRU4Rec、SASRec、CORE、FEARec、

S3Rec 六个序列推荐模型与 DIGER、DECOR 两个生成式推荐系统模型) 的复现配置为 LR=0.001、batch=4096 (FEARec 为 2048)、NDCG@10 早停, 其中 S3Rec 采用预训练 (向量化重构 50 epoch) 加微调的两阶段流程。结果汇总于表 4。

表 4: Amazon Musical_Instruments 5-core 复现结果对比 (按 Recall@10 升序)。

模型	Recall@5	Recall@10	NDCG@5	NDCG@10
序列推荐模型				
BERT4Rec	0.0660	0.0824	0.0528	0.0580
GRU4Rec	0.0713	0.0898	0.0577	0.0636
SASRec	0.0790	0.1033	0.0536	0.0614
CORE	0.0727	0.1054	0.0417	0.0523
FEARec	0.0853	0.1098	0.0595	0.0674
S3Rec	0.0834	0.1102	0.0561	0.0648
生成式推荐系统模型				
DIGER	0.0896	0.1127	0.0756	0.0831
DECOR	0.0925	0.1157	0.0784	0.0859

复现要点如下。Recall@10 上 S3Rec (0.1102) 最优, FEARec (0.1098)、CORE (0.1054)、SASRec (0.1033)、GRU4Rec (0.0898) 与 BERT4Rec (0.0824) 依次次之; NDCG@10 则由 FEARec (0.0674) 领先, 说明基于自监督/语义增强的序列模型在召回上具有竞争力。DECOR (0.1157) 与 DIGER (0.1127) 进一步达到约 0.11 的 Recall@10 目标水平。

Acknowledgments

本文工作使用了 HG-Rec (Zhang 等, ICML 2026) 的开源复现代码与 Amazon Review 2023 公开数据集。感谢 RQ-VAE、SID 与生成式推荐领域的相关研究工作。

References

- [1] Octavian Ganea, Gary Bécigneul, and Thomas Hofmann. 2018. Hyperbolic Neural Networks. In *Advances in Neural Information Processing Systems (NeurIPS '18)*.
- [2] Mikhael Gromov. 1987. Hyperbolic Groups. In *Essays in Group Theory*. Mathematical Sciences Research Institute Publications, Vol. 8. Springer, New York, NY, USA, 75–263. doi:10.1007/978-1-4613-9586-7_3
- [3] Dmitri Krioukov, Fragkiskos Papadopoulos, Maksim Kitsak, Amin Vahdat, and Marián Boguñá. 2010. Hyperbolic Geometry of Complex Networks. *Physical Review E* 82, 3 (2010), 036106. doi:10.1103/PhysRevE.82.036106
- [4] Doyup Lee, Changhoon Kim, Saehoon Kim, Minwoo Cho, and Wook-Shin Han. 2022. Autoregressive Image Generation using Residual Quantization. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR '22)*. IEEE, New Orleans, LA, USA, 11523–11532. doi:10.1109/CVPR52688.2022.01123
- [5] Maximilian Nickel and Douwe Kiela. 2017. Poincaré Embeddings for Learning Hierarchical Representations. In *Advances in Neural Information Processing Systems (NIPS '17)*.
- [6] Shashank Rajput, Nikhil Mehta, Anima Singh, Raghav Keshavan, Ludovico Staiano, Vikram Vinay, Sheril Ghosh, and Scott Sanner. 2023. Recommender Systems with Generative Retrieval. In *Advances in Neural Information Processing Systems (NeurIPS '23)*. Curran Associates, Inc., New Orleans, LA, USA.
- [7] Anima Singh, Davis D'Souza, Aditi Gupta, Tien-Wei Kuo, Alice Magnani, Fran Silavong, Shashank Rajput, Ludovico Staiano, Vikram Vinay, Sheril Ghosh, and Scott Sanner. 2024. Better Generalization with Semantic IDs. In *ACM Conference on Recommender Systems (RecSys '24)*. ACM, Bari, Italy.
- [8] TODO-AUTHOR. 2026. TopoTok: Topology-Preserving Tokenization for Generative Recommendation. In *TODO-VENUE*. 元数据待用户补充 (未在 Crossref/arXiv/Semantic Scholar 检索到)。

- [9] Jieming Zhu, Mengqun Jin, Qijiong Liu, Zexuan Qiu, Zhenhua Dong, and Xiu Li. 2024. CoST: Contrastive Quantization based Semantic Tokenization for Generative Recommendation. In *Proceedings of the 18th ACM Conference on Recommender Systems (RecSys '24)*. ACM, Bari, Italy, 969–974. doi:10.1145/3640457.

3688178